



Estatística para Engenharia

HOMEWORK
Estatística e probabilidade

Dupla:

João Pedro Rolim Ximenes- 566235

João Victor de Abreu Silva - 568274

Prof^ª: Michela Mulas

23/10/2025

1 Questão 1

As emissões diárias de um gás poluente de uma planta industrial foram registradas 80 vezes, em uma determinada unidade de medida. Os dados obtidos estão apresentados na Tabela 1

15.8	22.7	26.8	19.1	18.5	14.4	8.3	25.9	26.4	9.8	21.9	10.5
17.3	6.2	18.0	22.9	24.6	19.4	12.3	15.9	20.1	17.0	22.3	27.5
23.9	17.5	11.0	20.4	16.2	20.8	20.9	21.4	18.0	24.3	11.8	17.9
18.7	12.8	15.5	19.2	13.9	28.6	19.4	21.6	13.5	24.6	20.0	24.1
9.0	17.6	25.7	20.1	13.2	23.7	10.7	19.0	14.5	18.1	31.8	28.5
22.7	15.2	23.0	29.6	11.2	14.7	20.5	26.6	13.3	18.1	24.8	26.1
7.7	22.5	19.3	19.4	16.7	16.9	23.5	18.4				

Tabela 1: Emissões diárias de gás poluente (questão 1).

1.1 Calcule as medidas de tendência central (média, mediana e moda) e as medidas de dispersão (amplitude, variância, desvio padrão e coeficiente de variação) para o conjunto de dados da Tabela 1. Interprete os resultados

Para facilitar a leitura da questão e dos dados em análise, é possível que seja criado um algoritmo em R utilizando o Sort que organize os números de maneira crescente, assim, fica mais fácil de interpretar os dados. Após essa implementação, a tabela obtida é:

6.2	7.7	8.3	9.0	9.8	10.5	10.7	11.0	11.2	11.8
12.3	12.8	13.2	13.3	13.5	13.9	14.4	14.5	14.7	15.2
15.5	15.8	15.9	16.2	16.7	16.9	17.0	17.3	17.5	17.6
17.9	18.0	18.0	18.1	18.1	18.4	18.5	18.7	19.0	19.1
19.2	19.3	19.4	19.4	19.4	20.0	20.1	20.1	20.4	20.5
20.8	20.9	21.4	21.6	21.9	22.3	22.5	22.7	22.7	22.9
23.0	23.5	23.7	23.9	24.1	24.3	24.6	24.6	24.8	25.7
25.9	26.1	26.4	26.6	26.8	27.5	28.5	28.6	29.6	31.8

Tabela 2: Emissões diárias de gás poluente em ordem crescente utilizando sort (questão 1).

É possível responder o problema utilizando funções já conhecidas do R, como é o caso do mean e median, que já calculam automaticamente estas informações. No entanto, para melhor explanação, as fórmulas utilizadas são as seguintes:

$$\bar{x} = \text{média};$$

n = quantidade de elementos (utiliza o length para o vetor nesta questão vale 80)

x_i = elemento na posição (para média é a soma quantitativa de todos os elementos)

P = posição do elemento

A = amplitude

$x_{max,min}$ = valores máximo e mínimo

s = variância

CV = coeficiente de variação (em %)

Média (Soma de todos os elementos e divisão pela quantidade n deles):

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} \quad (1)$$

Mediana (quando o resultado é um número quebrado, faz-se a média entre os dois valores):

$$P = \frac{n+1}{2} \quad (2)$$

Para a moda deve-se contar a quantidade de vezes que cada elemento aparece, e o que mais se repetir torna-se a moda daquele espaço amostral.

Amplitude (é a relação entre o valor máximo e mínimo de um determinado conjunto de resultados):

$$A = x_{\max} - x_{\min} \quad (3)$$

Variância amostral (é feito a partir do somatório dos quadrados dos desvios simples sobre a quantidade elementos, neste caso):

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n} \quad (4)$$

Desvio padrão (de forma sucinta, é a raiz da variância):

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}} \quad (5)$$

Coeficiente de variação (se trata da relação percentual entre a variância e a média):

$$CV = \frac{s}{\bar{x}} \times 100\% \quad (6)$$

Com todos os cálculos devidamente apresentados, o resultado em R que calcula todos automaticamente foi a seguinte:

=== Medidas de Tendência Central ===

Média : 19.02

Mediana : 19.15 (lembrando que mediana é a média dos elementos entre as pos 40 e 41)

Moda : 19.4

=== Medidas de Dispersão ===

Amplitude : 25.6

Variância : 30.84

Desvio padrão : 5.55

Coeficiente de variação: 29.2%

Percebe-se assim que os resultados entram em concordância com os valores teóricos quando os cálculos são feitos à mão.

- 1.2 Construa um histograma e um boxplot para os dados de emissões. Os dados parecem estar simetricamente distribuídos? Existem valores atípicos?




Figura 1: Histograma q1.2




Figura 2: BoxPlot q1.2

Após a análise de ambos gráficos, é perceptível a partir do histograma que os dados estão simetricamente distribuídos, pois o gráfico decresce para ambos lados depois do pico da moda, ou seja, a média e a moda se encontram em valores similares, tal comportamento é evidenciado também no boxspot, onde é notório que a mediana está suficientemente próxima ao centro como o esperado (no intervalo entre os quartis), o que demonstra uma distribuição linear de resultados. Caso a média também estivesse evidenciada no BoxSpot, ao analisar novamente a q1.1, é visto que o resultado está também muito próximo ao da mediana. Tudo isto permite a percepção de uma distribuição quase simétrica de dados, com uma pequena tendência para a direita (a maior parte dos dados é um pouco maior do que os valores da média/mediana). Como visto no BoxPlot não existe valor atípico signi-

ficante, no entanto, para comprovar isso é feita a seguinte relação (descobrir outliers q1.3).

1.3 Determine os quartis (Q1, Q2, Q3) e o intervalo interquartil (IQR). Utilize esses valores para reforçar sua análise sobre a presença de valores atípicos

Primeiramente, calcula-se a amplitude interquartil:

$$IQR = Q_3 - Q_1 \quad (7)$$

Em seguida, determinam-se os limites inferior e superior (Outlier):

$$\text{Limite inferior} = Q_1 - 1.5 \times IQR \quad (8)$$

$$\text{Limite superior} = Q_3 + 1.5 \times IQR \quad (9)$$

Com base nesses limites, classificam-se os outliers da seguinte forma:

- Um valor x_i é considerado um outlier mínimo (inferior) se:

$$x_i < Q_1 - 1.5 \times IQR \quad (10)$$

- Um valor x_i é considerado um outlier máximo (superior) se:

$$x_i > Q_3 + 1.5 \times IQR \quad (11)$$

No caso, a partir dos dados da amostra, temos:

$$\begin{aligned} Q_1 &= 15,9 \quad ; \quad Q_3 = 23,3 \\ IQR &= Q_3 - Q_1 = 23,3 - 15,9 = 7,4 \end{aligned}$$

Os limites inferior e superior são calculados como:

$$\text{Limite inferior} = Q_1 - 1,5 \times IQR = 15,9 - 1,5(7,4) = 15,9 - 11,1 = 4,8$$

$$\text{Limite superior} = Q_3 + 1,5 \times IQR = 23,3 + 1,5(7,4) = 23,3 + 11,1 = 34,4$$

Assim, os valores considerados não atípicos pertencem ao intervalo:

$$[4,8, 34,4]$$

estes que não são ultrapassados por dados inferiores ou superiores, já que o menor dado é de 6.2 e o maior de 31.8, logo, não existem outliers.

1.4 Suponha que o limite máximo aceitável diário para as emissões seja de 25 unidades. Qual a proporção de dias em que a planta excedeu esse limite? O comportamento geral das emissões estaria em conformidade com esse padrão regulatório?

Para este item, é factível uma observação e relação rápida, onde podemos contar a quantidade de itens acima de 25.0 e a quantidade de itens do vetor. Isso pode ser feito dentro do R utilizando a função "length" para o vetor e um contador para quando os valores forem acima da margem estipulada. o resultado é o seguinte:

$$\begin{aligned}n &= 80 \\n_{>25} &= 11 \\p &= \frac{n_{>25}}{n} = \frac{11}{80} = 0,1375 \approx 13,8\%\end{aligned}$$

Portanto, aproximadamente 13,8% dos dias apresentaram emissões acima do limite de 25 unidades. Portanto, dependendo da margem de erro estipulada, está sim dentro ou não da conformidade, se for adotada uma de 10%, os valores excedem isto, no entanto, 13,8% ainda é um percentual baixo.

2 Questão 2

Uma empresa italiana recebeu 20 currículos de cidadãos italianos e estrangeiros na seleção de pessoal qualificado para o cargo de gerente de relações exteriores. A Tabela 3 reporta as informações consideradas relevantes na seleção: idade, nacionalidade, nível mínimo de renda desejada (em milhares de euros) e anos de experiência no trabalho.

Tabela 3: Idade, nacionalidade, renda desejada e anos de experiência dos candidatos.

Idade	Nacionalidade	Renda (mil €)	Experiência (anos)
28	Italiana	2.3	2
34	Inglesa	1.6	8
46	Belga	1.2	21
26	Espanhola	0.9	1
37	Italiana	2.1	15
29	Espanhola	1.6	3
51	Francesa	1.8	28
31	Belga	1.4	5
39	Italiana	1.2	13
43	Italiana	2.8	20
58	Italiana	3.4	32
44	Inglesa	2.7	23
25	Francesa	1.6	1
23	Espanhola	1.2	0
52	Italiana	1.1	29
42	Alemana	2.5	18
48	Francesa	2.0	19
33	Italiana	1.7	7
41	Alemana	2.1	12
36	Italiana	3.2	23

2.1 Calcule a média, mediana e desvio padrão para as variáveis idade, renda desejada e anos de experiência. O que você pode inferir a partir desses valores sobre o perfil típico dos candidatos?

Utilizando as funções e fórmulas já empregadas anteriormente na q1.1 e reutilizando seus conceitos, é factível um código em R que faz todas as operações automaticamente e dá como resultado as seguintes informações: neste caso, é importante ressaltar que o n é 20, pois é a quantidade total de pessoas no espaço amostral.

as fórmulas são as: 1 para média; 2 para mediana(para qualquer um dos dados; 5 para o desvio padrão utilizando as informações anteriores.

— Idade (anos) —

$n = 20$

Média = 38.65

Mediana = 38.50

Desvio padrão = 9.93

— Renda desejada (mil €) —

$n = 20$

Média = 1.92

Mediana = 1.75

Desvio padrão = 0.71

— Experiência (anos) —

$n = 20$

Média = 14.00

Mediana = 14.00

Desvio padrão = 10.27

Interpretação para Idade:

- Variabilidade moderada.

- Coeficiente de variação ($sd/mean$) = 0.26

Interpretação para Renda desejada:

- Variabilidade moderada.

- Coeficiente de variação ($sd/mean$) = 0.37

Interpretação para Experiência:

- Alta variabilidade relativa.

- Coeficiente de variação ($sd/mean$) = 0.73

2.2 Agrupe os candidatos por nacionalidade e calcule a renda média desejada e os anos médios de experiência para cada grupo. Qual nacionalidade apresenta a maior renda média desejada? Qual grupo aparenta ser o mais experiente?

Tabela 4: Tabela de nacionalidades e renda/experiência média

	Italiana	Inglês	Belga	Espanhola	Francesa	Alemanha
Quantidade	8	2	2	3	3	2
Renda média $Renda_i/Qty$	2,225	2,15	1,3	1,23	1,8	2,3
Experiência Exp_i/Qty	17,625	15,5	13	1,3	16	15

Para Exp sendo a soma de toda a experiência por nacionalidade e Renda sendo a soma da renda por nacionalidade. Percebe-se assim que os cálculos na mão dão resultados iguais aos do R, já que em ambos é possível notar que a maior renda média desejada foi a Alemã com 2,3 e a maior experiência de trabalho foi a Italiana, mesmo com a maior quantidade de candidatos. A saída do código em R de forma apresentável é a seguinte:

Nacionalidade /Renda_{media}/Exp_{media}

1Alemã/2.3/15

2Belga/1.3/13

3Espanhola/1.23/1.33

4Francesa/1.8/16

5Inglês/2.15/15.5

6Italiana/2.22/17.6

2.3 Existe correlação entre anos de experiência e renda desejada? Utilize ferramentas visuais apropriadas (por exemplo, gráfico de dispersão) e calcule o coeficiente de correlação de Pearson. Interprete o resultado

Para essa questão é necessário primeiro entendimento sobre o que é a correlação de Pearson que segundo o site é quando duas variáveis contínuas formam uma associação direta e linear com avanço (fator até +1) ou decremento (fator até -1) ou nula (fator 0) e isso é evidenciado na inclinação na reta, sendo para cima um aumento linear, e para baixo um decremento linear, sendo o declive indicação de como o coeficiente atua. No caso em

questão, é pedido para que se analise a experiência em função da pretensão salarial. Em R o seguinte gráfico é obtido:




Figura 3: Dispersão de Renda x Experiência (correlação de Pearson)

Ao analisar o gráfico, é perceptível que a reta está crescente, ou seja, geralmente, quanto mais anos de experiência, maior é a renda desejada, essa observação da correlação de Pearson permite analisar como uma variável pode influenciar em outra e demonstra uma maneira efetiva de entender o pensamento dentro de um espaço amostral reduzido.

Segundo o código em R, a correlação de Pearson também foi de 0,498, valor bastante próximo de 0,5, o que indica um avanço moderado, ou seja, geralmente as variáveis estão ligadas de uma maneira linear e seguindo um padrão de avanço.

2.4 Suponha que a empresa queira priorizar candidatos com pelo menos 10 anos de experiência e renda desejada inferior a 2,0 (mil euros). Quantos candidatos atendem a ambos os critérios? Liste suas nacionalidades e idades

Tabela 5: Candidatos com pelo menos 10 anos de experiência e renda desejada inferior a 2,0 mil euros

Nº	Idade	Nacionalidade	Renda (mil €)	Experiência (anos)
3	46	Belga	1.2	21
7	51	Francesa	1.8	28
9	39	Italiana	1.2	13
15	52	Italiana	1.1	29

Perceba que a candidata de índice 17 na tabela principal tem renda desejada exatamente 2000€ e apresenta a quantidade de tempo para experiência. Mas apenas 4 candidatos seguem fielmente aos parâmetros propostos.

2.5 Construa gráficos que permitam visualizar a distribuição da idade e da renda desejada, separados por nacionalidade. Utilize histogramas, box-plots ou gráficos de barras, e comente as principais diferenças observadas entre os grupos




Figura 4: q2.5.1

A partir da análise do boxplots da idade x nacionalidade, podemos tirar como conclusão:

- Franceses e Italianos apresentam a maior médias de idade, com as medianas mais elevadas entre todas as vistas;
- Espanhóis são o grupo mais jovem, único onde a concentração de idade está abaixo dos 30 anos;
- Belgas, ingleses e alemães apresenta uma faixa intermediária;
- Alemães representam o grupo com menor dispersão de resultados;
- Italianos e franceses apresentam os grupos com maior dispersão, indicando idades mais variadas
- Franceses apresentam uma clara concentração de idades mais altas.




Figura 5: q2.5.2

- Italianos pedem a maior renda dentre todos os grupos, no entanto, assim como nas idades, sua distribuição é bastante heterogênea, mas com mediana bem definida, ou seja, eles mantêm um padrão;
- Alemães retêm renda desejada alta mas com pouca dispersão, ou seja, os valores são mais altos para o grupo em si;
- Ingleses comparado a outros grupos apresentam uma renda desejada bem alta, com mediana superior a 2mil Euros;
- Franceses atuam em uma faixa intermediária dos dados, com uma dispersão não tão alta;
- Belgas e espanhóis são disparados as menores pretensões salariais, sendo que a dispersão dos espanhóis é ainda maior e com os dados puxados para baixo (mediana levemente mais para baixo do boxspot)

Em suma, é possível analisar com o conjunto de dados que a seguinte tabela resume as informações:

Nacionalidade	Idade média (tendência)	Renda desejada (tendência)	Observação principal
Espanhola	Baixa	Baixa	Jovens com baixa pretensão salarial
Italiana	Alta e muito variada	Alta e muito variada	Diversidade etária e salarial
Francesa	Alta	Intermediária	Candidatos mais experientes com rendas moderadas
Inglesa	Intermediária	Alta	Faixa média de idade com expectativa salarial elevada
Belga	Intermediária	Intermediária/baixa	Perfil estável e homogêneo
Alemã	Intermediária/alta	Alta	Candidatos mais velhos com pretensão salarial alta

Tabela 6: Resumo das tendências por nacionalidade

Os resultados da tabela entram em acordo com a correlação de Pearson, a medida de que os dados tendem a seguir certa proporcionalidade de resultados quando analisados simultaneamente, mostrando a relação presente e tendência de candidatos mais velhos desejarem salários mais altos e o inverso disso também ser válido.

3 Questão 3

Nessa questão, o foco é a análise de dados diretamente de um arquivo em .csv sobre o compartilhamento de bicicletas. Em cada item, a ideia principal é usar diferentes gráficos, escalas, conjuntos e cálculos para determinar com precisão informações dedicadas à prática estatística.

link do arquivo: HW1_bike_sharing.csv

3.1 Carregue o conjunto de dados HW1_bike_sharing.csv no R. Classifique as variáveis quanto ao tipo (categórica ou numérica), identifique o número total de observações e as datas de início e fim da amostra

- De início, usando as funções `min(dados$dteday)` e `max(dados$dteday)` pode-se determinar as datas de início e fim do monitoramento. As quais retornam os valores: 2011-01-01 e 2012-12-31 respectivamente.
- Segundamente, foi usado a função `nrow(dados)` para identificar o número total de observações
- Por fim, a classificação seguiu o padrão lógico de variável exata e variável de referência, a primeira se refere a um valor preciso e medido em quanto a segunda se refere a um valor demarcatório.

Tabela 7: Classificação das variáveis do *HW1_bike_sharing.csv*

Variável	Descrição	Tipo
<code>instant</code>	Índice de registro	Numérica
<code>dteday</code>	Data da observação	Categórica
<code>season</code>	Estação do ano	Categórica
<code>weathersit</code>	Condições meteorológicas	Categórica
<code>temp</code>	Temperatura em °C (normalizada)	Numérica
<code>casual</code>	Número de usuários casuais	Numérica
<code>registered</code>	Número de usuários registrados	Numérica

3.2 Calcule medidas de tendência central (média, mediana) e os quartis para cada característica numérica relevante. Apresente os resultados em uma tabela com título apropriado. Comente os principais pontos

- Nesse item, calculou-se medidas extremamente relevantes para avaliar os dados, medidas as quais o output em R tabelou e simplificou a visualização agrupada, permitindo comparações diretas e revisões por pares.
- Ademais, foi feito uma tabela em latex semelhante ao output, onde nota-se médias e medianas estritamente parecidas, fato esse que mostra com clareza a importância do domínio das funções em R como a `sapply` para comparações imediatas no data frame.

Cálculo das medidas de tendência central e dispersão

As medidas foram obtidas conforme as expressões abaixo.

- Média:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

- Mediana:

$$\tilde{X} = \begin{cases} X_{(\frac{n+1}{2})}, & \text{se } n \text{ for ímpar} \\ \frac{X_{(\frac{n}{2})} + X_{(\frac{n}{2}+1)}}{2}, & \text{se } n \text{ for par} \end{cases}$$

- Quartis:

$$Q_1 = X_{(0.25 \times (n+1))}, \quad Q_3 = X_{(0.75 \times (n+1))}$$

Tabela 8: Medidas de tendência central e quartis das variáveis numéricas do conjunto *HW1_bike_sharing.csv*

Variável	Média	Mediana	1º Quartil (Q1)	3º Quartil (Q3)
instant	366.00	366.0	183.5	548.5
temp	20.31	20.4	13.8	26.9
casual	848.18	713.0	315.5	1096.0
registered	3656.17	3662.0	2497.0	4776.5

3.3 Atribua os níveis correspondentes às variáveis *season* e *weathersit*. Construa gráficos de barras para ambas. Qual estação do ano apresenta maior número de usuários? O uso de bicicletas depende da estação? Qual é a condição climática mais favorável para o uso do sistema?

- a primeira tabela referente ao uso médio de bicicletas por estação do ano mostraram que verão, primavera e outono tiveram maior número de usos em comparação com o inverno, no qual o uso despencou.
- Já em relação à condição climática, pode-se notar que o céu limpo ou nublado é muito mais atrativo do que a chuva fraca e forte, inclusive não foi computado valores para chuva forte o que indica adesão nula nessa condição climática.

Cálculo do uso médio por estação e condição climática

Os gráficos de barras apresentados foram construídos a partir das médias de uso de bicicletas em função da estação do ano e das condições climáticas. As médias foram obtidas conforme as expressões a seguir.

- Uso médio por estação do ano:

$$\bar{U}_s = \frac{1}{n_s} \sum_{i \in S_s} U_i$$

- **Uso médio por condição climática:**

$$\bar{U}_c = \frac{1}{n_c} \sum_{i \in C_c} U_i$$

- **Forma geral (agrupamento por qualquer variável categórica G):**

$$\bar{U}_g = \frac{1}{n_g} \sum_{i \in G_g} U_i$$

Em que $U_i = \text{casual}_i + \text{registered}_i$ representa o total de usuários no dia i ; n_g é o número de observações no grupo g ; e $\bar{U}_g$ é o uso médio para cada categoria considerada.




Figura 6: Distribuição média de uso de bicicletas por estação do ano e condição climática.

Os resultados indicam que o uso médio de bicicletas é mais elevado durante o **verão**, mostrando que temperaturas mais altas são mais atrativos para a utilização do sistema. Em contraste, o inverno apresenta menor número de usuários.

Quanto às condições climáticas, nota-se que o **céu limpo** apresenta o maior número médio de locações, seguido por dias **nublados**. Nos dias com **chuva fraca** ou **chuva forte**, o número de usuários cai consideravelmente, mostrando que o clima tem forte influência no comportamento dos ciclistas.

3.4 Calcule o número total de usuários por dia, somando casual e registered. Converta a variável temp para temperatura real (multiplicando por 41). Em seguida, construa os gráficos de séries temporais para temperatura e número total de usuários. Essas séries apresentam tendência semelhante?

Análise da relação entre temperatura e número total de usuários


Inicialmente, calculou-se o número total de usuários diários, somando as quantidades de usuários casuais e registrados:

$$U_i = \text{casual}_i + \text{registered}_i$$

Em seguida, a variável `temp`, que representa a temperatura normalizada, foi convertida para a escala real em graus Celsius, conforme a relação:

$$T_i = 41 \times \text{temp}_i$$

Foram construídos dois gráficos de séries temporais: um representando a temperatura diária e outro o número total de usuários por dia. Muita Atenção, nesta ultima questão o código dos gráficos foi corrigido e feito uma segunda vez pelo ChatGPT, portanto, comentários no R foram de autoria dele.



(a) Série temporal da temperatura diária (°C) (b) Série temporal do número total de usuários

Figura 7: Séries temporais da temperatura e do número total de usuários.

Observa-se que ambas as séries apresentam **tendência semelhante**: nos períodos com temperaturas mais elevadas, o número total de usuários também tende a ser maior. Isso indica uma **relação positiva** entre temperatura e demanda pelo sistema de bicicletas, o que sugere que condições climáticas mais quentes trazem boa adesão ao uso do serviço.